Introduction to Bayesian Inference

1. Bayes' rule

$$p(heta \,|\, y) \,=\, rac{p(y \,|\, heta)\, p(heta)}{\displaystyle\int_{\Theta} \,p(y \,|\, ilde{ heta})\, p(ilde{ heta})\, d ilde{ heta}} \,\,\, \propto \,\,\, p(y \,|\, heta)\, p(heta)$$

새로운 정보를 토대로 어떤 사건이 발생했다는 주장에 대한 신뢰도(확률)를 갱신해 나가는 방법!

→ 뭘로? Likelihood로!

확률적인 배경 지식을 가지고 특별한 추가 정보 없이 샘플을 분류하는 예시를 생각해보자.

- 아무 사람이나 데리고 와서 남자인지 여자인지 분류하라고 하면 어떻게 분류할까? \rightarrow 세상에 절반은 남자, 절반은 여자이므로 50% 확률로 어림짐작 \rightarrow p(성별 = 남자) 혹은 p(성별 = 여자)
- haha ha의 삼색이를 데리고 와서 성별을 확인해본다고 하자. → 일반적으로 삼색 고양이는 성염색체 관련 이유로 대부분이 암컷으로 알려져 있음. → 매우 높은 확률로 삼색이는 암컷일 것임!

 θ : 모수

Θ : 모수 공간

y: 표본 데이터

 $p(\theta)$: 사전 확률. 현재 가지고 있는 정보를 기초로 하여 정한 초기 확률. 확률 시행 전에 이미가지고 있는 지식을 통해 부여한 확률.

 $p(y \mid \theta)$: 가능도. 어떤 값이 관측되었을 때 이 값이 어떤 확률분포에서 왔는지를 나타내는 확률. 추가되는 특정 정보!

 $p(\theta \mid y)$: 사후 확률. 사건 발생 후에 어떤 원인으로부터 일어난 것이라고 생각되어지는 확률. 추가된 정보로부터 사전 정보를 새롭게 수정한 확률(수정확률) \rightarrow 사전 지식만을 가지고구할 수 있다!

 $p(y) = \int_{\Theta} \; p(y \, | \, ilde{ heta}) \, p(ilde{ heta}) \, d ilde{ heta}$: Evidence. Normalizing Constant.

$$\int p(heta) \, d heta \, = \, 1, \quad \int p(heta \, | \, y) \, d heta \, = \, 1, \quad \int p(y \, | \, heta) \, d heta \,
eq \, 1$$

기존에 알고 있던 사전 지식에 추가 정보를 얹어주는 방식으로 '판단 근거 (사후 확률)'를 찾는 것!

- 판단 근거 = 사전 지식 \times 추가 정보
- 남자라고 판단할 근거 : $p(성별 = 남자) \times p(키 = 175 | 성별 = 남자)$
- 여자라고 판단할 근거 : $p(성별 = 여자) \times p(키 = 175 | 성별 = 여자)$
- → 사후확률은 가능도에 비례!

2. Example

① 사전 확률이 베타 분포(Beta Distribution)를 따르고, 가능도가 이항 분포를 따른다고 가정!

$$egin{aligned} heta &\sim Beta(lpha,eta) \longrightarrow p(heta) = rac{\Gamma(lpha+eta)}{\Gamma(lpha)\Gamma(eta)} heta^{lpha-1} \, (1- heta)^{eta-1} \end{aligned}$$

Prior

$$heta \, \sim \, Beta(2,20) \,
ightarrow \, p(heta) = rac{\Gamma(22)}{\Gamma(2)\Gamma(20)} heta \, (1- heta)^{19}$$

Likelihood

$$Y|\, heta \, \sim \, B(20, heta) \,
ightarrow \, p(y\,|\, heta) \, = \, inom{20}{y} \, heta^y \, (1- heta)^{20-y}$$

이항 분포에서 데이터가 관측되는 확률은 (0, 1) 사이의 값을 가지고, 베타 분포가 (0, 1) 사이의 값을 support로 갖기 때문에, 사전 확률은 reasonable하다고 할 수 있다!

$$egin{aligned} p(y\,|\, heta)\,p(heta) &= egin{pmatrix} 20 \ y \end{pmatrix} heta^y\,(1- heta)^{20-y}\,rac{\Gamma(22)}{\Gamma(2)\Gamma(20)} heta\,(1- heta)^{19} \ &= rac{\Gamma(20+1)}{\Gamma(y+1)\,\Gamma(20-y+1)}rac{\Gamma(22)}{\Gamma(2)\Gamma(20)} heta^{2+y-1}\,(1- heta)^{20+20-y-1} \ &= egin{pmatrix} (n+1) \ y!\,(n-y)! &= rac{\Gamma(n+1)}{\Gamma(y+1)\,\Gamma(n-y+1)} \end{pmatrix} \end{aligned}$$

$$\begin{split} p(y) &= \int_0^1 \, p(y \,|\, \theta) \, p(\theta) \, d\theta \\ &= \int_0^1 \, \binom{20}{y} \, \theta^y \, (1-\theta)^{20-y} \, \frac{\Gamma(22)}{\Gamma(2)\Gamma(20)} \theta \, (1-\theta)^{19} \, d\theta \\ &= \frac{\Gamma(20+1)}{\Gamma(y+1) \, \Gamma(20-y+1)} \frac{\Gamma(22)}{\Gamma(2)\Gamma(20)} \int_0^1 \theta^{2+y-1} \, (1-\theta)^{20+20-y-1} \, d\theta \\ &= \frac{\Gamma(n+1)\Gamma(\alpha+\beta)\Gamma(y+\alpha)\Gamma(n-y+\beta)}{\Gamma(y+1)\Gamma(n-y+1)\Gamma(\alpha)\Gamma(\beta)\Gamma(\alpha+\beta+n)} \\ &= \frac{\Gamma(20+1)\Gamma(2+20)\Gamma(y+2)\Gamma(20-y+20)}{\Gamma(y+1)\Gamma(20-y+1)\Gamma(2)\Gamma(20)\Gamma(2+20+20)} \\ p(\theta \,|\, y) &= \frac{\Gamma(n+\alpha+\beta)}{\Gamma(y+\alpha)\Gamma(n-y+\beta)} \, \theta^{y+\alpha-1} \, (1-\theta)^{\beta+n-y-1} \\ p(\theta \,|\, y) &= \frac{\Gamma(20+2+20)}{\Gamma(y+2)\Gamma(20-y+20)} \, \theta^{y+2-1} \, (1-\theta)^{20+20-y-1} \end{split}$$

$$egin{aligned} &=rac{\Gamma(2+40)}{\Gamma(y+2)\Gamma(40-y)} heta^{y+2-1}\,(1- heta)^{40-y-1} \ &= heta\,|\,Y=0\,\sim\,Beta(2+y,\,40-y) \ &p(heta)=Beta(heta\,|\,lpha,eta)\,\,\longrightarrow\,\,p(heta\,|\,y)=Beta(heta\,|\,lpha+y,\,eta+n-y) \end{aligned}$$

prior과 posterior가 같은 분포 형태를 가질 때, "prior is conjugate to the likelihood"라고 한다!

$$\mathbb{E}(\theta) = \frac{\alpha}{\alpha + \beta}, \quad \mathbb{E}(\theta \mid y) = \frac{\alpha + y}{\alpha + \beta + n}$$

$$\mathbb{E}(\theta \mid y) = \frac{\alpha + y}{\alpha + \beta + n} = \frac{\alpha}{\alpha + \beta} \frac{\alpha + \beta}{(\alpha + \beta + n)} + \frac{y}{n} \frac{n}{(\alpha + \beta + n)}$$

$$(w = \alpha + \beta)$$

$$=rac{n}{w+n} imes\hat{ heta}_{ML} \; (sample \; mean) \, + \, rac{w}{w+n} imes \mathbb{E}(heta) \; (prior \; mean)$$

how posterior information is affected by prior mean and strength of prior belief

사후확률의 평균은 사전확률의 평균과 MLE 값의 Weighted sum으로 표현될 수 있다! n이 커짐에 따라 prior mean은 posterior mean 에 영향을 끼치지 않게 된다! 즉, 우리가 사전에 설정한 prior knowledge가 옳지 않았다 하더라도 그 영향이 줄어들게 된다는 것으로서, 좋은 성질이라 할 수 있다!

Wald Test

$$\hat{ heta} \, \pm \, 1.96 \, \sqrt{rac{\hat{ heta}(1-\hat{ heta})}{n}}, \quad \hat{ heta} = rac{y}{n}$$

Wald interval is asymptotically correct when n is large

Determination of prior

Hard to precisely, mathematically represent our belief, and actually it's wrong $all\ models\ are\ wrong,\ but\ some\ are\ useful.$

3. Belief

$$Be(\,\cdot\,)\equiv$$
 우리가 명제를 믿는 정도를 숫자로 나타내 주는 함수

$$F = \{ a \ person \ votes \ for \ a \ left-of-center \ candidate \}$$

$$G = \{ a \ person's \ income \ is \ in \ the \ lowest \ 10\% \ of \ the \ population \}$$

$$H = \{ a \ person \ lives \ in \ a \ large \ city \}$$

믿음의 공리

①
$$Be(\sim H \,|\, H) \leq Be(F \,|\, H) \leq Be(H \,|\, H)$$
 $0 = P(\sim H \,|\, H) \leq P(F \,|\, H) \leq P(H \,|\, H) = 1$

②
$$Be(F \ or \ G \ | \ H) \geq \max \{ Be(F \ | \ H), Be(G \ | \ H) \}$$
 $P(F \cup G \ | \ H) = P(F \ | \ H) + P(G \ | \ H) \quad if \quad F \cap G = \emptyset$

3 $Be(F \ and \ G \ | \ H \) \ can \ be \ derived \ from \ Be(G \ | \ H \) \ and \ Be(F \ | \ G \ and \ H)$ $P(F \cap G \ | \ H \) = P(G \ | \ H \) \cdot P(F \ | \ G \cap H \)$

4. Events, Partitions and Bayes' rule

A collection of sets $\{H_1, ..., H_k\}$ is a partition of another set H if

- 1. the events are disjoint, which we write as $H_i \cap H_j = \emptyset$ for $i \neq j$
- 2. the union of the sets is H, which we write as $\bigcup_k H_k = H$.

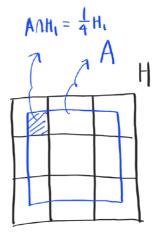
From above, we get three rules from axioms of probability.

Rule of total probability: $\sum_k P(H_k) = 1$

Rule of marginal probability:
$$P(A) = \sum_{k} P(A \cap H_{k}) = \sum_{k} P(A|H_{k})P(H_{k})$$

Bayes' rule: $P(H_{j}|A) = \frac{P(A|H_{j})P(H_{j})}{\sum_{k}(A|H_{k})} = \frac{P(A \cap H_{k})}{P(A)}$

Bayes' rule:
$$P(H_j|A) = \frac{P(A|H_j)P(H_j)}{\sum_k (A|H_k)} = \frac{P(A)}{P(A)}$$



Conditional independence : parameter θ 에 대한 조건부 환경에서도 일반적인 독립의 정의가 성립함.

$$P(Y_1 \in A_1, ..., Y_n \in A_n | \theta) = P(Y_1 \in A_1 | \theta) \times ... \times P(Y_n \in A_n | \theta)$$

$$\rightarrow P(Y_i \in A_i | \theta, Y_i \in A_i) = P(Y_i \in A_i | \theta)$$

$$\rightarrow p(y_1, ..., y_n | \theta) = \prod_i p(y_i | \theta)$$

5. Exchangeability

Let
$$p(y_1,...,y_n)$$
 be the joint density of $Y_1,...,Y_n$.
If $p(y_1,...,y_n) = p(y_{\pi_1},...,y_{\pi_n})$
for all permutations π of $\{1,...,n\}$, then $Y_1,...,Y_n$ are exchangeable.

$$\begin{bmatrix} Y_1 \\ Y_2 \\ Y_3 \end{bmatrix} \sim N_3 \begin{pmatrix} \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix}, \begin{bmatrix} 100 \\ 0 & 0 \\ 0 & 0 \end{bmatrix} \end{pmatrix} / \sim N_3 \begin{pmatrix} \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix}, \begin{bmatrix} 122 \\ 212 \\ 221 \end{bmatrix} \end{pmatrix} / \sim N_3 \begin{pmatrix} \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix}, \begin{bmatrix} 125 \\ 214 \\ 541 \end{bmatrix} \end{pmatrix}$$

독립의 약 조건!

6. de Finetti's theorem

베이즈 추론의 정당성을 부여하는 정리!

- 1) Conditional IID ⇒ exchangeability (곱셈)
- 2) Conditional IID ← infinite exchangeability: de finetti's therem

$$p(y_1,\dots,y_n) = \int \left\{ \prod_i p(y_i|\theta) \right\} \, p(\theta) \; d\theta$$

 \Rightarrow decomposition of the model

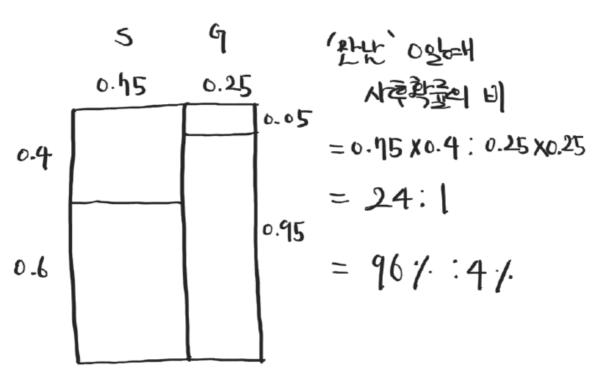
교환 가능 확률 변수족 - 위키백과, 우리 모두의 백과사전

확률론과 통계학에서, 교환 가능 확률 변수족(交換可能確率變數族, exchangeable family of random variables)은 유한 개를 재배열하여도 결합 확률 분포가 변하지 않는 확률 변수 집합이다. 교환 가능 시그마 대수(交換可能o代數, exchangeable sigma-algebra)는 유한 개의 확률 변수를 재배열하여도 발생 여부가 바뀌지 않는 사건들로 구성된 시

W https://ko.wikipedia.org/wiki/%EA%B5%90%ED%99%98_%EA%B0%80%EB%8A%A5_%ED%99%95%EB%A5%A0_%EB%B3%80%EC%88%98%EC%A1%B1

Method 1) 한번에 처식 0.5x0.2x0.05					
1			小儿、毕此 0 99叶		
	0.500.640.4	0.580.280.95	小寺社会 日		
		o-5Xo.8Xo.05	= 0.5x0.6x0.4:		
		3, 0,, 3	0.5X0.2X0.05		
	0.5x0.6x0.6		= 24:1		
		0.5X0.8X0.95	= 96%:4%		
	0.5X0.4 X0.4				
	0.5X0.4 X0.6				
			J		

Method 2) 台外记, 叶中鸡叫 外部 2000 /

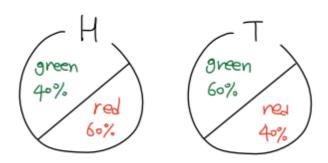


HW

2.5

Urns: Suppose urn H is filled with 40% green balls and 60% red balls, and urn T is filled with 60% green balls and 40% red balls. Someone will flip a coin and then select a ball from urn H or urn T depending on whether the coin lands heads or tails, respectively. Let X be 1 or 0 if the coin lands heads or tails, and let Y be 1 or 0 if the ball is green or red.

a) Write out the joint distribution of X and Y in a table.



동전 앞면 → um H의 공 선택 동전 뒷면 → um T의 공 선택

YX	1	0
1	$\frac{1}{2} \times \frac{40}{100} = 0.2$	$\frac{1}{2} \times \frac{60}{100} \approx 0.3$
0	1x60 = 0.3	$\frac{1}{2} \times \frac{40}{100} = 0.2$

b) Find ${\cal E}[Y].$ What is the probability that the ball is green?

$$E[Y] = E[E[Y|X]]$$

$$= E[Y|X=1] \cdot P(X=1) + E[Y|X=0] \cdot P(X=0)$$

$$= \frac{40}{100} \times \frac{1}{2} + \frac{60}{100} \times \frac{1}{2} = 0.5$$

$$P(Y=1) = P(Y=1, X=1) + P(Y=1, X=0)$$

$$= 0.2 + 0.3 = 0.5$$

c) FInd $Var[Y \mid X=0]$, $Var[Y \mid X=1]$ and Var[Y]. Thinking of variance as measuring uncertainty, explain intuitively why one of these variances is larger than the others.

$$Vor[Y|X=0] = E[Y^2|X=0] - \{E[Y|X=0]\}^2$$

$$= \frac{60}{100} - (\frac{60}{100})^2 = 0.6 - 0.36 = 0.24$$

$$Vor[Y|X=1] = E[Y^{2}|X=1] - \{E[Y|X=1]\}^{2}$$

$$= \frac{40}{100} - (\frac{40}{100})^{2} = 0.4 - 0.16 = 0.24$$

$$V_{or}[Y] = E[V_{or}[Y|X]] + V_{or}[E[Y|X]]$$

$$= (\frac{1}{2} \times 0.24 + \frac{1}{2} \times 0.24) + \frac{1}{2} \{ E[Y|X=1] - E[Y] \}^{2}$$

$$+ \frac{1}{2} \{ E[Y|X=0] - E[Y] \}^{2}$$

$$= 0.24 + (\frac{10}{100})^{2} = 0.25$$

d) Suppose you see that the ball is green. What is the probability that the coin turned up tails?

posterior
$$P(T|Y=1) = \frac{P(T \cap Y=1)}{P(Y=1)} = \frac{P(Y=1|T) \cdot P(T)}{0.5}$$

$$= \frac{\frac{3}{5} \times \frac{1}{2}}{\frac{1}{2}} = \frac{3}{5}$$
Likelihood prior
$$P(Y=1) = \frac{P(Y=1|T) \cdot P(T)}{0.5}$$
Evidence

2.6

Conditional independence: Suppose events A and B are conditionally independent given C, which is written $A\perp B\mid C$. Show that this implies that $A^c\perp B\mid C$, $A\perp B^c\mid C$, and $A^c\perp B^c\mid C$, where A^c means "not A." Find an example where $A\perp B\mid C$ holds but $A\perp B\mid C^c$ does not hold.

Pólya urn model - Wikipedia

In statistics, a Pólya urn model (also known as a Pólya urn scheme or simply as Pólya's urn), named after George Pólya, is a type of statistical model used as an idealized mental exercise framework, unifying many treatments. In an urn model, objects of real interest (such as atoms, people, cars, etc.)

 $W \ \ \text{https://en.wikipedia.org/wiki/P\%C3\%B3lya_urn_model}$